

확률에 대한 간략한 소개

데이터 요약 방법을 익혔으므로, 이제 이러한 요약 수치를 바탕으로 통계적 추론(Statistical inference)을 활용해 주어진 질문에 답해 보겠습니다. 통계적 추론을 올바르게 수행하려면 확률(Probability)에 대한 기본적인 이해가 필수적입니다. 많은 통계적 추론 과정이 결국 “특정 가설이 참일 때, 우리가 이보다 더 극단적인 데이터를 관찰할 가능성은 얼마입니까?”라는 질문으로 귀결되기 때문입니다. 바로 그 가능성을 정량화하기 위해 확률이 필요합니다.

확률론은 현대 통계학과 달리 1600년대부터 학문적 토대를 다져왔습니다. 초기에는 도박과 관련된 문제를 해결하기 위해 여러 규칙과 정리가 고안되었으나, 파스칼(Pascal), 페르마(Fermat), 베르누이(Bernoulli), 가우스(Gauss) 등 수학사에서 중요한 학자들이 참여하며 분야가 크게 발전했습니다.

우리는 일상에서 흔히 확률을 접합니다. 일기 예보에서 비나 눈이 올 확률을 확인하고, 스포츠 경기 전후로 특정 팀의 승리 확률을 논합니다. 물론 확률론의 기원이라 할 수 있는 도박에서도 크랩스, 포커, 룰렛, 블랙잭의 배당률 형태로 확률을 마주합니다. 그럼에도 불구하고 확률과 그 기저에 있는 일반적인 개념에 관해서는 종종 오해가 발생합니다. 본 장에서는 통계적 추론에서 다시 다루게 될 확률의 기초와 핵심 개념들을 소개하겠습니다. 무작위 현상(Random phenomena), 확률 변수(Random variables), 확률의 역할, 그리고 확률의 규칙에 내재된 개념부터 차례로 살펴보겠습니다.

0.1 무작위 현상, 확률, 그리고 대수의 법칙

본격적인 논의에 앞서, 확률이 왜 필요하며 어떤 역할을 하는지 짚고 넘어가야 합니다. 간단히 말해, 확률은 무작위 현상을 설명하는 데 유용합니다. 무작위 현상(Random phenomenon)이란 결과를 미리 알 수 없는 모든 사건을 의미합니다. 동전 던지기부터 개인의 키, 혹은 최근 생성형 AI가 특정 프롬프트에 대해 어떤 단어를 다음 토큰으로 예측할지에 이르기까지 그 범위는 매우 넓습니다. 사건의 결과를 미리 확정할 수 없다면 그것은 무작위 현상입니다. 그리고 확률(Probability)은 이러한 무작위 현상의 결과가 나타날 가능성을 정량화하는 방법론입니다.

확률을 해석하는 관점에는 주관적 확률(Subjective probability), 고전적 확률(Classical probability), 빈도주의적 확률(Frequentist probability) 등 여러 가지가 있습니다. 주관적 확률은 결과 발생 가능성에 대한 개인의 주관적인 믿음에 근거합니다. 이 관점에서는 확률이 사람마다 다르게 평가될 수 있습니다. 흥미로운 철학적 논의가 많지만, 본 교재에서는 깊이 다루지 않겠습니다.

두 번째는 고전적 확률입니다. 고전적 확률에서 특정 사건의 확률은 그 사건에 속하는 가능한 결과들의 비율로 정의됩니다. 구조가 단순한 상황에서는 매우 유용하지만, 가능한 모든 결과가 발생할 확률이 동일하다는 가정을 전제로 한다는 한계가 있습니다. 현실에서는 이러한 가정이 성립하기 어려운 경우가 많으므로, 이 가정을 요구하지 않는 빈도주의적 확률 해석이 등장하게 됩니다.

가장 널리 쓰이는 해석은 빈도주의적 확률 모델입니다. 이 관점의 핵심은 무작위 현상을 무수히 반복하면, 사건 발생 비율이 실제 참 확률에 점점 더 가까워진다는 것입니다. 이를 확률에 대한 장기적 비율 관점(Long-run proportion view)이라고도 부릅니다.

동전을 던져 앞면이 나올 확률을 알고 싶다고 가정해 보겠습니다. 동전이 공정하다면 앞면이 나올 확률은 0.5여야 합니다. 동전을 반복해서 계속 던지면, 앞면이 나온 횟수의 비율은 결국 0.5에 수렴할 것입니다.

이러한 장기적 비율 관점이 성립하는 이유는 통계학의 대수의 법칙(Law of Large Numbers) 때문입니다. 이 법칙은 표본 크기가 커질수록(즉, $n \rightarrow \infty$), 표본 평균(Sample mean) $\bar{x}$ 가 실제 모평균(Mean)

μ 에 수렴한다는 것을 의미합니다. 마찬가지로 표본 크기가 커질수록 표본 비율(Sample proportion) $\hat{p}$ 역시 실제 비율 p 에 수렴합니다. 수학적으로는 다음과 같이 표현합니다.

$$\lim_{n \rightarrow \infty} \bar{x} = \mu \quad \lim_{n \rightarrow \infty} \hat{p} = p$$

예를 들어, 공정한 6면체 주사위를 굴러 특정 숫자가 나올 확률은 1/6입니다. 굴리는 횟수가 무한대로 커지면 3이 나올 비율 역시 1/6에 수렴합니다.

0.2 추론에서 확률의 역할은 무엇입니까?

이제 확률의 정의와 일반적인 쓰임새를 알게 되었습니다. 그렇다면 통계적 추론에서 확률은 어떤 역할을 할까요? 확률은 무작위 현상을 설명함으로써 불확실성을 정량화하는 데 도움을 줍니다. 2025년 현재 AI가 환각(Hallucination) 없이 정확한 답변을 생성할 가능성을 평가할 때처럼, 확률은 우리가 내린 결론에 대해 얼마나 확신할 수 있는지를 수치로 나타냅니다.

다음 상황을 상상해 보십시오. 상대방과 각각 5달러를 걸고 게임을 합니다. 상대방이 주사위를 굴러 6이 나오면 그가 돈을 가져가고, 다른 숫자가 나오면 여러분이 이깁니다. 일반적으로는 여러분이 이길 확률이 5배 높으므로 매우 유리한 게임입니다. 그런데 상대방이 5번 연속으로 6을 던져 25달러를 따냈다고 가정해 보겠습니다. 두세 번 연속 6이 나왔을 때는 그저 운이 좋았다고 생각할 수 있습니다. 하지만 다섯 번 연속이라면 주사위가 조작되었거나 상대방이 속임수를 썼다고 의심하게 될 것입니다. 이러한 의심은 합리적입니다. 공정한 주사위와 정당한 게임 환경에서 5번 연속 6이 나올 확률은 1/7776으로, 극히 희박한 사건이기 때문입니다.

비슷한 예로, 공정하다고 믿는 동전을 20번 던져 앞면이 나오는 횟수를 세어 보겠습니다. 완전히 공정하다면 앞면이 10번 나올 것으로 예상합니다. 그런데 12번이 나왔다면 어떨까요? 혹은 14번이라면 동전이 불공정하다고 의심할 수 있을까요? 앞면이 몇 번 이상 나와야 의심이 확신으로 바뀔까요? 이것이 바로 통계적 추론의 핵심 논리입니다. 즉, 세상의 특정 상태를 가정하고, 데이터를 수집한 뒤, 그 데이터가 애초의 가정을 기각할 만큼 충분히 극단적인지 평가하는 것입니다. 확률은 이 판단 과정을 수치화해 주며, 이후 장에서 더욱 자세히 다루겠습니다.

0.3 확률 계산과 확률의 공리

확률을 논할 때는 실제 무작위 현상에서 특정 결과(Outcome)가 발생할 가능성을 계산하는 과정이 수반됩니다. 가능성을 정확히 계산하려면, 해당 무작위 현상에서 나타날 수 있는 모든 결과의 전체 목록을 파악해야 합니다. 이 전체 목록을 표본 공간(Sample space)이라고 하며, 보통 S 로 표기합니다. 예를 들어 동전을 한 번 던질 때 표본 공간은 앞면과 뒷면, 즉 $S = \{H, T\}$ 입니다. 동전을 두 번 던진다면 표본 공간은 $S = \{HH, HT, TH, TT\}$ 로 확장됩니다. 마찬가지로 주사위 두 개를 굴러 그 합을 관찰한다면 표본 공간은 $S = \{2, 3, 4, \dots, 10, 11, 12\}$ 가 됩니다.

모든 가능성을 나열하고 나면, 임의의 사건(Event)에 대한 확률을 계산할 수 있습니다. 사건은 표본 공간의 부분 집합을 의미하며, 주로 대문자 알파벳(A, B 등)으로 표기합니다. 동전을 두 번 던지는 현상